

# Kaggle 50 Startups

## 利潤預測技術白皮規格書

CRISP-DM Framework | Machine Learning Pipeline | Technical Whitepaper &  
Specification

# Kaggle 50 Startups 利潤預測

Homework 6 Submission • CRISP-DM Framework • 2026/06/11



目標：根據新創公司的支出特徵預測 Profit

## ① 專案總覽



資料集：  
50 筆資料



任務：  
Profit Prediction




工作流程：  
CRISP-DM




工作目錄：  
d:/cena/0611/HW6

## ② CRISP-DM 流程



## ③ EDA 重點發現



★ R&D Spend 與 Profit 高度相關 ( $R \approx 0.97$ )

★ Administration 與 Profit 關聯很弱 ( $R \approx 0.20$ )


★ 最重要特徵：R&D Spend

## ④ 前處理與特徵工程

自訂 FeatureEngineer

- 建立 interaction terms、log terms、budget ratios
- ColumnTransformer
- StandardScaler 處理數值特徵
- OneHotEncoder(drop='first') 處理 State
- test\_size = 0.19
- random\_state = 0

## ⑤ 模型比較



★ 使用 5-fold CV 進行 GridSearchCV (正則化模型)

## ⑥ 模型表現 (核心表格)

| 特徵數 | 選擇特徵                                                                        | Linear $R^2$ | Ridge $R^2$ | Lasso $R^2$ | ElasticNet $R^2$ | Random Forest $R^2$ |
|-----|-----------------------------------------------------------------------------|--------------|-------------|-------------|------------------|---------------------|
| 1   | [R&D Spend]                                                                 | 0.9465       | 0.9461      | 0.9465      | 0.9463           | 0.9328              |
| 2   | [R&D Spend, Marketing Spend]                                                | 0.9474       | 0.9470      | 0.9474      | 0.9473           | 0.9366              |
| 3   | [R&D Spend, Marketing Spend, State_New York]                                | 0.9460       | 0.9458      | 0.9460      | 0.9459           | 0.9366              |
| 4   | [R&D Spend, Marketing Spend, State_New York, State_Florida]                 | 0.9447       | 0.9445      | 0.9447      | 0.9446           | 0.9366              |
| 5   | [R&D Spend, Marketing Spend, State_New York, State_Florida, Administration] | 0.9347       | 0.9346      | 0.9347      | 0.9347           | 0.9366              |

## ⑦ 關鍵洞察

最佳特徵數 = 2


★ 最佳特徵組合 = [R&D Spend, Marketing Spend]

最佳表現：  
 $R^2 = 94.74\%$   
RMSE = 8,198.80




加入 Administration 會降低泛化能力

- Linear model 的 RMSE 從 8,198.80 增加到 9,137.99
- 增幅約 11.4%



## ⑧ 部署成果



★ 讓 VC 快速評估新創公司投資潛力！



Data → Insight → Impact



日期  
方法論  
工作目錄  
交付定位

2026/06/11  
CRISP-DM Framework  
d:/cena/0611/HW6  
技術白皮書 + 系統規格書

# 文件目錄

1. 文件目的與適用範圍
2. 專案背景與問題定義
3. 成功準則與驗收標準
4. CRISP-DM 方法論總覽
5. 資料集規格
6. 欄位字典與資料語意
7. 資料探索分析規格
8. EDA 關鍵發現
9. 資料切分與實驗可重現性
10. 特徵工程規格
11. 前處理管線規格
12. 模型候選集合
13. 特徵子集合設計
14. 超參數調校規格
15. 模型效能表與解讀
16. 最佳模型決策
17. Administration 特徵風險分析
18. 部署架構規格
19. API 與函式規格
20. 檔案與目錄結構規格
21. 測試策略與品質保證
22. 風險、限制與假設
23. 安全性、隱私與治理
24. 維運與模型監控
25. 報告、簡報與溝通規格
26. 未來擴充方向
27. 結論

# 摘要

本技術白皮規格書依據 Kaggle 50 Startups 利潤預測專案撰寫，內容涵蓋 CRISP-DM 全流程、資料規格、EDA 發現、特徵工程、模型比較、最佳模型決策、部署函式、測試策略、風險治理與未來擴充方向。專案以 50 筆新創公司資料為基礎，根據支出特徵預測 Profit，並透過 Linear Regression、Ridge Regression、Lasso Regression、ElasticNet 與 Random Forest 進行比較。最終結果顯示，最佳特徵組合為 R&D Spend 與 Marketing Spend，最佳表現為  $R^2=94.74\%$ 、 $RMSE=8,198.80$ ，且 Administration 的加入會降低泛化能力。

文件同時可作為課堂報告、技術審查、模型交付與簡報延伸材料。所有章節均以繁體中文撰寫，保留必要英文技術名詞，以利用在機器學習、資料分析與系統規格三種語境之間保持精準。

## 核心模型效能表

| 特徵數 | 選擇特徵                                                                        | Linear $R^2$ | Ridge $R^2$ | Lasso $R^2$ | ElasticNet $R^2$ | Random Forest $R^2$ |
|-----|-----------------------------------------------------------------------------|--------------|-------------|-------------|------------------|---------------------|
| 1   | [R&D Spend]                                                                 | 0.9465       | 0.9461      | 0.9465      | 0.9463           | 0.9328              |
| 2   | [R&D Spend, Marketing Spend]                                                | 0.9474       | 0.9470      | 0.9474      | 0.9473           | 0.9366              |
| 3   | [R&D Spend, Marketing Spend, State_New York]                                | 0.9460       | 0.9458      | 0.9460      | 0.9459           | 0.9366              |
| 4   | [R&D Spend, Marketing Spend, State_New York, State_Florida]                 | 0.9447       | 0.9445      | 0.9447      | 0.9446           | 0.9366              |
| 5   | [R&D Spend, Marketing Spend, State_New York, State_Florida, Administration] | 0.9347       | 0.9346      | 0.9347      | 0.9347           | 0.9366              |

## 1. 文件目的與適用範圍

本白皮規格書旨在將 Kaggle 50 Startups 利潤預測專題，從一般作業摘要提升為可交付、可驗收、可維護的技術文件。文件同時涵蓋白皮書與規格書兩種視角：白皮書負責說明問題背景、方法選擇、分析邏輯與決策依據；規格書負責定義資料欄位、流程步驟、模型訓練、評估標準、部署方式與維運要求。讀者可以透過本文件理解專案為何採用 CRISP-DM、如何從資料探索走到模型部署，以及最終模型如何被用於新創公司預算與投資潛力的快速評估。

本文件的適用範圍以 50 Startups 資料集為核心，目標變數為 Profit，輸入特徵主要包含 R&D Spend、Administration、Marketing Spend 與 State。文件不假設讀者已閱讀程式碼，但會保留必要的技術術語，例如 ColumnTransformer、StandardScaler、OneHotEncoder、GridSearchCV 與 predict\_profit()。本文件亦可作為簡報、程式碼審查、課堂報告、模型交付與後續擴充的基準文件。若未來加入更多公司資料、更多財務欄位或更完整的部署平台，本規格可作為版本演進的起點。



- 建立統一技術敘事，避免只呈現模型分數而缺乏業務解釋。
- 保留可重現參數，例如 `test_size=0.19` 與 `random_state=0`。
- 將 EDA、模型比較與部署輸出串成完整生命週期。

| 編號      | 規格項目 | 需求描述                  | 驗收標準                   |
|---------|------|-----------------------|------------------------|
| DOC-001 | 文件範圍 | 內容必須涵蓋資料、流程、模型、評估與部署。 | 所有章節均可對應到 CRISP-DM 階段。 |
| DOC-002 | 語言格式 | 主體以繁體中文撰寫，技術名詞保留英文。   | 讀者可直接用於中文課堂報告。         |

## 2. 專案背景與問題定義

新創公司早期營運通常面臨資金配置、成長速度與市場開發之間的取捨。若能利用既有公司支出資料預測 Profit，投資人、創業團隊或課程評審即可用較客觀的方式理解不同支出項目對收益的影響。本專題選擇 Kaggle 50 Startups 資料集作為案例，目的不是建立大型商用財務模型，而是用精簡、結構化的資料示範機器學習專案如何從業務問題出發，轉換為可訓練、可比較、可部署的預測流程。

在問題定義上，本專案屬於監督式學習中的迴歸問題。模型需要根據公司支出與地區資料，輸出一個連續數值 Profit。由於資料量僅 50 筆，專案更重視資料理解、特徵選擇、交叉驗證、泛化能力與可解釋性，而不是盲目追求複雜模型。此背景也解釋了為何本專案同時比較線性模型、正則化模型與 Random Forest，並用不同特徵子集合觀察模型效能變化。

- 業務問題：如何根據支出配置預測公司利潤。
- 技術問題：如何在小資料集上建立穩健迴歸模型。
- 決策問題：哪些特徵值得保留，哪些特徵可能造成噪音。

## 3. 成功準則與驗收標準

本專案的成功不僅取決於單一  $R^2$  分數，而是取決於整體機器學習流程是否完整、結果是否可解釋、模型是否能夠序列化並被呼叫。從白皮書角度來看，成功準則包含：能清楚說明資料來源與欄位意義、能用 EDA 支持特徵選擇、能比較多種模型、能指出最佳特徵組合、能交付可部署模型。從規格書角度來看，成功準則包含：所有關鍵參數可重現、模型效能表格可追溯、部署檔案與預測函式命名明確。

驗收時應避免只看最高分數。由於資料集小，若模型過度依賴單次切分或過多衍生特徵，可能在測試集上看似優秀但缺乏穩定性。因此本專案採用 5-fold CV、GridSearchCV 與多特徵子集合比較，將「分數」與「泛化能力」一起納入決策。最佳模型不是最複雜的模型，而是能在簡潔特徵下保持高  $R^2$ 、低 RMSE 且便於解釋與部署的模型。

- $R^2$  作為主要解釋能力指標。
- RMSE 作為誤差大小與商業風險的量化指標。
- 部署檔 `startup_profit_model.pkl` 必須能支援 `predict_profit()`。

| 編號      | 規格項目 | 需求描述           | 驗收標準                                                        |
|---------|------|----------------|-------------------------------------------------------------|
| ACC-001 | 模型效能 | 最佳特徵組合需達到高解釋力。 | $R^2$ 約 94.74%，RMSE 約 8,198.80。                             |
| ACC-002 | 可重現性 | 資料切分與隨機參數必須固定。 | <code>test_size=0.19</code> ， <code>random_state=0</code> 。 |
| ACC-003 | 可交付性 | 模型需序列化為可部署檔案。  | 產出 <code>startup_profit_model.pkl</code> 。                  |

## 4. CRISP-DM 方法論總覽

CRISP-DM 是本專案的主軸，原因在於它能將資料科學工作拆解成可管理、可審查的階段。對於課堂作業或小型專案而言，常見問題是直接跳到建模，導致資料探索與業務理解不足。本專案明確依序經過 Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation 與 Deployment，使每一步都有產物與驗收依據。

在本專案中，Business Understanding 對應到「用支出預測 Profit」；Data Understanding 對應到直方圖、散佈圖、類別圖與相關係數熱圖；Data Preparation 對應到特徵工程、數值標準化與類別編碼；Modeling 對應到五種演算法與五組特徵子集合；Evaluation 對應到  $R^2$ 、RMSE 與模型比較表；Deployment 對應到 `startup_profit_model.pkl` 與 `predict_profit()`。這種對應方式可使專案報告具備完整邏輯，並降低評審只看到零散程式碼與圖表的風險。

- Business Understanding：定義商業目標與預測輸出。
- Data Understanding：用圖表與統計量觀察資料。
- Data Preparation：建立可訓練的資料管線。
- Modeling：訓練與調參多個候選模型。
- Evaluation：比較模型與解釋決策。
- Deployment：保存模型並提供預測介面。

## 5. 資料集規格

資料集包含 50 筆新創公司紀錄，主要欄位包含 R&D Spend、Administration、Marketing Spend、State 與 Profit。前三者為數值型支出欄位，State 為類別欄位，Profit 為迴歸任務的目標欄位。因為資料筆數有限，任何缺失值、離群值、錯誤型別或類別編碼問題都可能對模型造成顯著影響，因此資料理解階段必須比大型資料專案更加謹慎。

資料規格應將欄位角色明確分開：輸入特徵負責描述公司資源投入與地區資訊，目標變數負責衡量預測結果。R&D Spend 通常可視為產品或技術研發投入，Marketing Spend 可視為市場推廣成本，Administration 可視為行政管理支出，State 則可能反映不同地區的營運環境。本專案後續發現 R&D Spend 與 Profit 高度相關，而 Administration 與 Profit 關聯較弱，這些發現都需要回到欄位語意來解讀。

| 編號       | 規格項目 | 需求描述            | 驗收標準                                        |
|----------|------|-----------------|---------------------------------------------|
| DATA-001 | 資料筆數 | 資料集固定為 50 筆紀錄。  | EDA 與模型訓練報告需反映小資料限制。                        |
| DATA-002 | 目標欄位 | Profit 為唯一目標變數。 | 模型輸出為連續數值。                                  |
| DATA-003 | 類別欄位 | State 需經類別編碼。   | 使用 <code>OneHotEncoder(drop=first)</code> 。 |

## 6. 欄位字典與資料語意

欄位字典是模型規格的重要基礎。若欄位語意不清楚，即使模型分數很高，也可能難以被業務端採納。本專案中的 R&D Spend、Administration、Marketing Spend 皆屬於支出型數值欄位，但其業務意義不同。R&D Spend 更接近產品研發與技術能力投入，Marketing Spend 更接近市場取得與品牌推廣，Administration 則偏向日常營運與管理成本。這些語意差異會反映在模型係數、相關係數與特徵重要性上。

State 欄位則代表公司所在地區。由於它是類別資料，不能直接送入大多數數值模型，必須透過 OneHotEncoder 轉換。設定 `drop=first` 的原因，是避免在加入截距項的線性模型中產生完全共線性。Profit 為模型要預測的結果，因此在所有資料前處理與特徵工程步驟中都不可被錯誤地用作輸入特徵，以避免資料洩漏。

- R&D Spend：核心研發支出，與 Profit 的線性關係最明顯。
- Administration：行政管理支出，可能包含較多噪音。
- Marketing Spend：行銷推廣支出，與 R&D Spend 搭配後可提升模型表現。
- State：地區類別特徵，需要轉為模型可讀的數值欄位。
- Profit：預測目標，不可作為輸入特徵。

## 7. 資料探索分析規格

資料探索分析負責回答三類問題：資料長什麼樣、特徵與目標是否相關、是否有類別或分布差異。專案中已產出四個主要圖檔：`histograms.png`、`scatter_plots.png`、`categorical_plots.png` 與 `correlation_heatmap.png`。這些圖檔分別對應分布檢查、雙變量關係檢查、類別比較與整體相關矩陣。若未來重跑專案，這四類圖仍應被視為最低限度的 EDA 產物。

EDA 的重點不是把所有圖都放進報告，而是要從圖中抽取能支援建模決策的洞察。散佈圖可顯示 R&D Spend 與 Profit 的線性趨勢，相關熱圖可用 Pearson correlation 量化此趨勢；直方圖可檢查欄位分布是否偏斜，類別圖可觀察 State 對 Profit 是否存在明顯差異。這些探索結果最終支援特徵子集合設計與模型選擇。

- `histograms.png`：觀察數值欄位與 Profit 的分布。
- `scatter_plots.png`：觀察各支出欄位與 Profit 的散佈關係。
- `categorical_plots.png`：觀察 State 類別與 Profit 的差異。
- `correlation_heatmap.png`：量化欄位間 Pearson correlation。

## 8. EDA 關鍵發現

本專案最重要的 EDA 結論是：R&D Spend 與 Profit 呈現高度正相關，相關係數約  $R \approx 0.97$ 。此結果意味著在 50 Startups 資料中，研發投入與公司獲利能力之間具有非常強的線性關係。這不代表研發支出在所有真實商業情境中必然造成利潤提升，但在此資料集與此任務中，R&D Spend 是最具預測力且最容易被解釋的特徵。

相對地，Administration 與 Profit 的關聯很弱，相關係數約  $R \approx 0.20$ 。這項發現後續也在模型比較中被驗證：當 Administration 加入特徵集合時，線性模型的 RMSE 從 8,198.80 增加到 9,137.99，增幅約 11.4%。此結果表示 Administration 可能在此資料集上帶來較多噪音，增加模型複雜度卻未提升泛化能力。因此，本專案建議將 Administration 排除在最佳預測模型之外。

- R&D Spend 是最重要特徵，具備高度預測力。
- Marketing Spend 與 R&D Spend 搭配後形成最佳兩特徵組合。
- Administration 在此資料集上更像噪音特徵。
- EDA 發現與模型評估結果彼此一致。

## 9. 資料切分與實驗可重現性

資料切分是小資料迴歸專案中的關鍵風險。若切分方式不同，測試集組成就可能改變，模型分數也可能產生明顯波動。因此，本專案固定 `test_size=0.19` 與 `random_state=0`，以便重現驗證指標。`test_size=0.19` 代表測試集比例約為 19%，在 50 筆資料情境下可保留足夠訓練資料，同時仍提供獨立驗證集合。



可重現性不只包含資料切分，也包含特徵工程順序、預處理管線、模型參數搜尋範圍、交叉驗證折數與輸出檔案命名。所有會影響模型結果的設定都應集中紀錄，避免在報告、簡報與程式碼之間產生落差。若未來需要加入新資料，建議使用版本化資料集與實驗紀錄表，清楚標示每一次訓練所使用的資料版本與模型版本。

- 固定 `random_state=0`。
- 固定 `test_size=0.19`。
- 保存模型比較表與最佳模型輸出。
- 若重新訓練，需保存訓練日期、資料版本與程式版本。

| 編號      | 規格項目 | 需求描述              | 驗收標準           |
|---------|------|-------------------|----------------|
| EXP-001 | 資料切分 | 訓練與測試資料必須固定切分設定。  | 重跑後可得到一致的驗證結果。 |
| EXP-002 | 實驗紀錄 | 模型、特徵、參數與分數需成表保存。 | 可追蹤最佳模型產生過程。   |

## 10. 特徵工程規格

本專案設計自訂 `FeatureEngineer`，用於動態產生 `interaction terms`、`log terms` 與 `budget ratios`。特徵工程的目的不是任意增加欄位，而是將可能存在的非線性關係、比例關係與支出組合效應轉換成模型可學習的訊號。例如，研發支出與行銷支出可能共同影響 `Profit`；單一支出額度也可能因規模差異而需要透過 `log` 轉換降低偏斜；不同支出占比則可描述公司資源配置策略。

然而，在小資料集上進行特徵工程必須特別保守。每增加一個特徵，就可能提高過擬合風險。因此，`FeatureEngineer` 應被放入 `Pipeline` 中，讓訓練資料與測試資料使用相同轉換邏輯，同時避免手動處理造成資料洩漏。若未來擴充更多特徵，建議將每個衍生特徵的名稱、公式、輸入欄位、缺值處理方式與預期業務解釋寫入特徵字典。

- `interaction terms`：描述多個支出欄位的共同效果。
- `log terms`：降低偏斜與尺度不均問題。
- `budget ratios`：描述支出配置比例。
- 所有特徵工程應納入 `Pipeline`，不應在訓練前手動散落處理。

## 11. 前處理管線規格

前處理管線使用 `ColumnTransformer` 統一處理不同資料型態。數值欄位透過 `StandardScaler` 標準化，使其平均值與標準差被轉換到適合線性模型與正則化模型訓練的尺度。類別欄位 `State` 透過 `OneHotEncoder(drop=first)` 轉成虛擬變數，讓模型能利用地區資訊，同時避免線性模型中的虛擬變數陷阱。

前處理步驟必須與模型訓練綁定在同一個 `Pipeline` 中。這樣做的優點是：第一，降低測試集資訊洩漏；第二，讓部署端不需要手動重寫前處理邏輯；第三，使 `startup_profit_model.pkl` 可以完整保存從原始輸入到預測輸出的處理流程。若部署端只保存模型而未保存前處理器，將導致線上預測輸入格式與訓練格式不一致，產生嚴重的維運風險。

- `ColumnTransformer`：根據欄位型態分流處理。
- `StandardScaler`：處理數值欄位尺度。
- `OneHotEncoder(drop=first)`：處理 `State` 類別欄位。
- `Pipeline`：將特徵工程、前處理與模型整合。

| 編號 | 規格項目 | 需求描述 | 驗收標準 |
|----|------|------|------|
|----|------|------|------|

|         |       |                          |                      |
|---------|-------|--------------------------|----------------------|
| PRE-001 | 數值標準化 | 數值欄位需進入 StandardScaler。  | 模型訓練與預測使用同一轉換器。      |
| PRE-002 | 類別編碼  | State 需進入 OneHotEncoder。 | drop=first 以降低共線性風險。 |
| PRE-003 | 管線化   | 前處理不得與模型分離部署。            | 序列化檔案需包含完整 pipeline。 |

## 12. 模型候選集合

本專案共訓練五類模型：Linear Regression、Ridge Regression、Lasso Regression、ElasticNet 與 Random Forest。模型集合同時涵蓋基準線性模型、正則化線性模型與非線性集成模型。Linear Regression 提供最直觀的基準；Ridge 可透過 L2 正則化降低係數不穩；Lasso 可透過 L1 正則化產生稀疏效果；ElasticNet 結合 L1 與 L2；Random Forest 則提供非線性與樹模型比較。

選擇這五種模型的核心原因是平衡解釋性與效能。在只有 50 筆資料時，太複雜的模型未必可靠，因此線性與正則化模型通常是良好起點。Random Forest 雖然可捕捉非線性，但在本結果中並未超越最佳線性類模型。這表示資料中的主要訊號可能已被 R&D Spend 與 Marketing Spend 的線性關係充分表達。

- Linear Regression：基準模型，解釋性高。
- Ridge Regression：降低係數波動。
- Lasso Regression：支援稀疏化與特徵選擇。
- ElasticNet：折衷 L1 與 L2。
- Random Forest：非線性樹模型比較基準。

## 13. 特徵子集合設計

模型比較不是只比較演算法，也比較特徵數量。本專案依序使用五組特徵子集合，從單一 R&D Spend 開始，再加入 Marketing Spend、State\_New York、State\_Florida 與 Administration。這種設計可觀察每新增一個特徵是否真的提升模型表現，避免因為欄位看似完整就全部納入。

結果顯示，最佳特徵數為 2，最佳特徵組合為 [R&D Spend, Marketing Spend]。當加入 State 相關特徵後， $R^2$  未明顯提升；當加入 Administration 後，線性模型表現反而下降。此結論對規格設計非常重要，因為部署模型應採用兼具簡潔性與泛化能力的特徵集合，而不是追求欄位越多越好。

- Subset 1：[R&D Spend]。
- Subset 2：[R&D Spend, Marketing Spend]。
- Subset 3：加入 State\_New York。
- Subset 4：加入 State\_Florida。
- Subset 5：加入 Administration。

## 14. 超參數調校規格

對於 Ridge、Lasso 與 ElasticNet 等正則化模型，本專案使用 GridSearchCV 與 5-fold cross-validation 進行超參數搜尋。交叉驗證的目的，是在有限資料中更穩健地估計模型泛化能力，降低單一次訓練測試切分造成的偶然性。GridSearchCV 則提供系統化搜尋方式，使 alpha 或 l1\_ratio 等參數不只是憑直覺設定。

超參數調校應遵循可重現與可解釋原則。每個候選參數範圍都應保存，最佳參數應與模型分數一起輸出。若未來改用 RandomizedSearchCV 或 Bayesian Optimization，也需要記錄搜尋空間、隨機種子與評估指標。

本專案目前以 5-fold CV 作為合理折衷：既能提供比單次切分更穩定的估計，也不會因資料量太小而造成過高運算複雜度。

- GridSearchCV：系統化搜尋正則化模型超參數。
- 5-fold CV：提升小資料集上的評估穩定性。
- 評估指標需與最終報告一致。
- 調校結果應可與模型比較表對應。

## 15. 模型效能表與解讀

模型效能表顯示，在兩個特徵 [R&D Spend, Marketing Spend] 下，Linear Regression 與 Lasso Regression 均達到 0.9474 的  $R^2$ ，為本次比較中的最高表現。Ridge 在同一特徵組合下為 0.9470，ElasticNet 為 0.9473，Random Forest 為 0.9366。這代表最佳解不一定來自更複雜模型，而是來自正確的特徵選擇與穩定的線性關係。

從特徵數變化來看，單一 R&D Spend 已可達到 0.9465，加入 Marketing Spend 後提升到 0.9474，但再加入 State 或 Administration 後並未提升，甚至下降。這種現象顯示資料的主要訊號集中在少數支出欄位中。對實務決策而言，簡潔模型也較容易解釋：投資人或管理者可以直接理解研發與行銷投入對利潤預測的重要性，而不必依賴難以說明的黑箱特徵。

## 16. 最佳模型決策

最佳模型決策需同時考量  $R^2$ 、RMSE、特徵數、可解釋性與部署便利性。本專案選定最佳特徵組合為 [R&D Spend, Marketing Spend]，最佳表現為  $R^2=94.74\%$ ，RMSE=8,198.80。此結果表示模型能解釋大部分 Profit 變異，且平均誤差規模在此資料設定下相對可接受。

若只以  $R^2$  觀察，Linear Regression 與 Lasso Regression 在最佳特徵組合下分數相同。實務上可依部署策略選擇：若最重視直觀解釋與教學展示，可採 Linear Regression；若希望保留正則化與特徵稀疏化能力，可採 Lasso Regression。由於專案摘要指出最佳模型 pipeline 已序列化為 startup\_profit\_model.pkl，本規格建議在模型卡中明確標示實際採用模型類型、版本與訓練資料日期。

- 最佳特徵數：2。
- 最佳特徵組合：[R&D Spend, Marketing Spend]。
- 最佳  $R^2$ ：94.74%。
- 最佳 RMSE：8,198.80。
- Administration 不納入最佳模型。

## 17. Administration 特徵風險分析

Administration 是本專案中最具教學意義的反例。直覺上，行政支出也是公司成本之一，似乎應該納入模型；但資料分析顯示其與 Profit 的相關係數約 0.20，模型比較也顯示加入該欄位後泛化能力下降。這提醒我們，機器學習特徵選擇不能只依靠業務直覺，也不能只靠欄位是否容易取得，而必須用資料與驗證結果共同判斷。

當 Administration 加入特徵集合後，線性模型 RMSE 從 8,198.80 增加到 9,137.99，增幅約 11.4%。這代表模型預測誤差變大，可能是因為 Administration 欄位包含與 Profit 無直接穩定關係的支出波動。規格上應將 Administration 標示為「不建議納入目前最佳模型」的特徵，除非未來有更多資料或更完整的營運分類可重新驗證。

- 特徵關聯弱： $R \approx 0.20$ 。

- 加入後 RMSE 增加約 11.4%。
- 目前定位為噪音或低貢獻特徵。
- 未來若資料擴充，仍可重新評估。

## 18. 部署架構規格

部署成果包含 `startup_profit_model.pkl` 與 `predict_profit()`。前者保存訓練完成的模型 `pipeline`，後者提供快速呼叫介面，使使用者能輸入支出資料並取得 `Profit` 預測值。部署規格的核心要求是：部署端必須使用與訓練端一致的前處理與模型版本，且輸入欄位順序、型別與單位需符合訓練資料規格。

在簡易課堂專案中，部署可以是本機 Python 函式；在進階情境中，則可包裝為 `Flask API`、`FastAPI` 服務或批次預測腳本。不論部署型態為何，都應保留模型載入、輸入驗證、錯誤處理、輸出格式與日誌紀錄。若部署端輸入缺少 `R&D Spend` 或 `Marketing Spend`，系統應回傳明確錯誤，而不是默默填入不合理預設值。

- 模型檔：`startup_profit_model.pkl`。
- 預測函式：`predict_profit()`。
- 輸入需包含最佳特徵欄位。
- 輸出為 `Profit` 預測值。
- 部署端需驗證欄位型別與缺失值。

| 編號      | 規格項目 | 需求描述                                             | 驗收標準                                          |
|---------|------|--------------------------------------------------|-----------------------------------------------|
| DEP-001 | 模型保存 | 最佳 <code>pipeline</code> 需保存為 <code>pkl</code> 。 | 檔案名稱為 <code>startup_profit_model.pkl</code> 。 |
| DEP-002 | 預測介面 | 需提供 <code>predict_profit()</code> 。              | 輸入合法時回傳 <code>Profit</code> 預測。               |
| DEP-003 | 輸入檢查 | 缺少必要欄位時不得直接預測。                                   | 回傳可理解錯誤訊息。                                    |

## 19. API 與函式規格

`predict_profit()` 是本專案最小可用部署介面。函式設計應以穩定、簡潔、容易測試為原則。建議輸入可以是單筆字典、`DataFrame` 或具名參數，但無論採用哪種形式，都必須明確要求必要欄位，例如 `R&D Spend` 與 `Marketing Spend`。若部署版本仍保留 `State` 或其他欄位，也必須定義可接受類別與缺省處理方式。

函式輸出應包含至少一個 `Profit` 預測值。若用於 `VC` 快速評估，也可額外輸出模型版本、特徵組合、預測時間與警告訊息。白皮書建議不要把預測結果解讀為保證利潤，而應說明它是根據歷史資料與支出特徵估計的數值。若輸入值超出訓練資料常見範圍，函式應產生警告，以避免模型外推造成誤導。

- 建議輸入：`R&D Spend`、`Marketing Spend`。
- 建議輸出：`predicted_profit`。
- 可選輸出：`model_version`、`feature_set`、`warning`。
- 若輸入超出合理範圍，需提醒使用者。

## 20. 檔案與目錄結構規格

專案工作目錄為 `d:/cena/0611/HW6`。依照摘要，主要程式檔包含 `solve_50_startups.py`，EDA 圖檔位於 `plots/` 目錄，最終模型輸出為 `startup_profit_model.pkl`。目錄結構應支援清楚的責任分離：程式碼、資料、圖表、模型、報告與簡報不應混在同一層，否則後續審查與部署時容易發生版本混亂。



建議的目錄設計包含 `data/`、`plots/`、`models/`、`reports/`、`src/` 與 `notebooks/`。若維持目前課堂作業結構，也至少應在 `README` 中說明每個檔案用途。特別是 `plots/allinone.png`，因其承載 RMSE 與 R-squared 曲線比較，應被視為評估產物之一；`startup_profit_model.pkl` 則應被視為部署產物，不應與中間實驗模型混淆。

- `src/`：放置 `solve_50_startups.py` 與可重用程式。
- `plots/`：保存 EDA 與模型比較圖。
- `models/`：保存 `startup_profit_model.pkl`。
- `reports/`：保存白皮書、簡報與提交文件。
- `README`：說明執行方式與產物位置。

## 21. 測試策略與品質保證

品質保證應涵蓋資料測試、管線測試、模型測試與部署測試。資料測試確認欄位存在、型別正確、缺失值處理符合預期；管線測試確認 `FeatureEngineer`、`ColumnTransformer` 與模型可以在訓練與預測階段順利串接；模型測試確認重跑後可取得接近既有報告的  $R^2$  與 RMSE；部署測試確認 `predict_profit()` 對合法輸入可回傳預測，對非法輸入可回傳錯誤。

對小資料專案而言，品質保證不應過度複雜，但必須涵蓋最容易出錯的地方。常見錯誤包含：欄位名稱大小寫不一致、`State` 類別在部署端出現訓練時未見過的值、標準化器未與模型一起保存、測試集資料意外參與前處理 `fit`、模型檔案版本錯誤。這些問題都可能讓模型在展示時失敗，因此應在提交前建立簡單測試清單。

- 資料欄位完整性測試。
- 前處理 `pipeline` 可執行測試。
- 模型分數回歸測試。
- `predict_profit()` 合法與非法輸入測試。
- 模型檔案存在性與載入測試。

| 編號     | 規格項目 | 需求描述                      | 驗收標準                 |
|--------|------|---------------------------|----------------------|
| QA-001 | 欄位檢查 | 必要欄位不得缺失。                 | 缺欄位時測試失敗。            |
| QA-002 | 模型載入 | <code>pkl</code> 檔可被成功載入。 | 載入後可執行單筆預測。          |
| QA-003 | 分數回歸 | 重跑結果需接近文件分數。              | $R^2$ 與 RMSE 不應大幅偏離。 |

## 22. 風險、限制與假設

本專案最大的限制是資料筆數只有 50 筆。小資料集容易受到切分、離群值與單筆資料影響，模型分數也可能較不穩定。因此，白皮書不應將此模型描述為可直接用於真實投資決策的完整系統，而應定位為資料科學流程示範、快速評估原型或課堂作業成果。若要投入真實商業使用，必須蒐集更多公司樣本與更多財務指標。

第二個限制是欄位有限。`Profit` 可能受市場規模、產品成熟度、團隊能力、競爭環境、資金成本、時間因素與產業類別影響，但目前資料集中只包含少數支出與地區欄位。因此，模型捕捉的是此資料集內的統計關係，而非完整商業因果關係。文件中所有結論應以「在本資料集與本實驗設定下」為前提，避免過度推論。

- 資料量小，泛化能力需謹慎解讀。
- 欄位不足，無法完整描述新創公司營運。
- 模型結果代表統計關係，不等於因果關係。
- 若輸入超出訓練範圍，預測可信度下降。



## 23. 安全性、隱私與治理

雖然本資料集不涉及真實個資，但任何模型部署都應具備基本治理概念。資料來源、資料版本、模型版本、訓練日期與評估結果都應被記錄。若未來使用真實公司資料，則需要處理商業機密、財務敏感資訊與存取權限。模型輸出也不應被視為唯一決策依據，而應搭配人工審查與背景調查。

治理上，建議將模型卡、資料卡與變更紀錄納入交付。模型卡說明模型用途、限制、輸入輸出、評估指標與已知風險；資料卡說明資料來源、欄位定義、處理方式與限制；變更紀錄則描述每次模型更新的差異。這些文件能讓專案從一次性作業轉變為可持續維護的系統。

- 保存模型版本與資料版本。
- 避免將預測結果作為唯一投資依據。
- 若使用真實公司資料，需處理權限與保密。
- 建立模型卡與資料卡。

## 24. 維運與模型監控

若本模型進入長期使用，維運重點將從一次性分數轉向持續監控。模型監控應觀察輸入資料分布是否改變、預測誤差是否增加、使用者輸入是否常出現超出訓練範圍的值，以及模型是否因市場環境改變而失效。小型課堂專案可以用手動紀錄方式監控；正式系統則可建立自動化日誌與定期報表。

模型再訓練策略應根據資料新增速度決定。若每月新增大量公司資料，可設定定期再訓練；若資料更新緩慢，則可在模型表現明顯下降或欄位定義改變時再訓練。每次再訓練都應與舊模型比較，不能只因新模型分數稍高就替換，還要確認特徵穩定性、輸入相容性與部署風險。

- 監控輸入分布漂移。
- 監控預測誤差與使用者回饋。
- 保存每次再訓練結果。
- 更新模型前需進行新舊版本比較。

## 25. 報告、簡報與溝通規格

本專案已有 20 頁簡報需求，因此白皮書內容應能映射到簡報架構。簡報適合呈現重點、流程圖、模型表與結論；白皮書則補充規格、理由、限制與驗收方式。兩者不應互相矛盾。簡報的核心敘事可以是：先說明業務問題，再展示 CRISP-DM 流程，接著用 EDA 支持特徵選擇，最後用模型比較表與部署成果收尾。

對評審或老師溝通時，建議突出三個亮點：第一，專案不是只訓練一個模型，而是完整走過 CRISP-DM；第二，最佳特徵組合只有兩個，代表模型兼具效能與解釋性；第三，Administration 雖然是可取得欄位，但加入後降低泛化能力，這顯示專案有進行真正的特徵驗證，而非機械式丟入所有欄位。

- 簡報強調視覺化與結論。
- 白皮書強調規格、推理與驗收。
- 所有數字需與模型效能表一致。
- 報告中應明確標示最佳特徵與最佳分數。

## 26. 未來擴充方向

未來擴充可分為資料擴充、模型擴充、部署擴充與決策擴充。資料擴充方面，可加入更多公司樣本、產業類別、成立年限、員工數、融資輪次、市場規模與時間序列資料。模型擴充方面，可嘗試 Gradient Boosting、XGBoost、LightGBM 或 Bayesian Regression，但前提是資料量足夠支持更複雜模型。

部署擴充方面，可將 `predict_profit()` 包裝為 Web API，並建立簡易前端讓使用者輸入支出資料。決策擴充方面，可不只輸出單點 Profit 預測，也提供信賴區間、情境分析與敏感度分析。例如使用者可以調整 R&D Spend 與 Marketing Spend，觀察 Profit 預測如何變化。這會讓模型從單次預測工具進化為預算規劃輔助系統。

- 新增更多公司資料與財務欄位。
- 建立 API 或網頁介面。
- 加入情境分析與敏感度分析。
- 提供預測區間而非只有單點估計。

## 27. 結論

本專案以 Kaggle 50 Startups 資料集完成完整利潤預測流程，從業務理解、資料探索、資料準備、模型訓練、效能評估到部署輸出皆有明確產物。核心結論是：R&D Spend 是最重要特徵，R&D Spend 與 Marketing Spend 組成的兩特徵模型達到最佳平衡， $R^2$  約 94.74%，RMSE 約 8,198.80。這說明在此資料集上，簡潔且可解釋的模型已能取得高品質結果。

本白皮規格書將原始作業摘要轉換為可交付文件，使專案不只是一段程式或一張表格，而是一套可重現、可驗收、可部署的機器學習解決方案。未來若擴充資料與部署環境，仍可沿用本文件的規格架構，逐步演進為更完整的新創公司財務預測與投資評估平台。

- Data → Insight → Impact。
- 用資料支持特徵選擇。
- 用模型比較支持最終決策。
- 用部署介面支持實際應用。

## 附錄 A：術語表

| 術語            | 說明                                     |
|---------------|----------------------------------------|
| CRISP-DM      | 跨產業資料探勘標準流程，包含業務理解、資料理解、資料準備、建模、評估與部署。 |
| $R^2$         | 模型解釋目標變異的比例，越高代表解釋能力越強。                |
| RMSE          | 均方根誤差，用來衡量預測值與真實值的平均誤差規模。              |
| Pipeline      | 將前處理、特徵工程與模型訓練串接成一致流程的機制。              |
| GridSearchCV  | 以交叉驗證方式搜尋最佳超參數的工具。                     |
| OneHotEncoder | 將類別欄位轉換為數值虛擬變數的編碼方法。                   |

## 附錄 B：交付物清單

- `solve_50_startups.py`：主求解與訓練程式。
- `plots/histograms.png`：資料分布圖。
- `plots/scatter_plots.png`：支出與 Profit 散佈關係圖。
- `plots/categorical_plots.png`：State 類別分析圖。
- `plots/correlation_heatmap.png`：Pearson correlation heatmap。
- `plots/allinone.png`：模型 RMSE 與 R-squared 比較圖。
- `startup_profit_model.pkl`：最佳模型 pipeline 序列化檔。
- `predict_profit()`：部署端快速預測函式。

本文件完稿時的核心結論為：最佳特徵數為 2，最佳特徵組合為 [R&D Spend, Marketing Spend]，最佳模型表現為  $R^2=94.74\%$ 、 $RMSE=8,198.80$ 。此結論應隨資料版本與模型版本一起保存，後續若重新訓練，需建立新版本文件。

## 附錄 C：延伸技術說明

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查 pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查 pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查 pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第

三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 **Administration** 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，**Profit** 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 **Profit**。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 **R&D Spend** 與 **Marketing Spend** 不可被簡化為 **RD** 或 **Marketing** 而未同步更新 **pipeline**。第二，模型載入端應檢查 **pkl** 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 **Profit**。第二層是資料語言：**R&D Spend** 與 **Profit** 的相關係數很高，而 **Administration** 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 **Administration** 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，**Profit** 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 **Profit**。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 **R&D Spend** 與 **Marketing Spend** 不可被簡化為 **RD** 或 **Marketing** 而未同步更新 **pipeline**。第二，模型載入端應檢查 **pkl** 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 **Profit**。第二層是資料語言：**R&D Spend** 與 **Profit** 的相關係數很高，而 **Administration** 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 **Administration** 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，**Profit** 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 **Profit**。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 **R&D Spend** 與 **Marketing Spend** 不可被簡化為 **RD** 或 **Marketing** 而未同步更新 **pipeline**。第二，模型載入端應檢查 **pkl** 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。



在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查.pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查.pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查.pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。



第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查 pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

在教學展示情境中，建議將模型結果拆成三層說明。第一層是業務語言：研發與行銷投入能較好地解釋 Profit。第二層是資料語言：R&D Spend 與 Profit 的相關係數很高，而 Administration 的相關係數很低。第三層是模型語言：兩特徵組合達到最佳  $R^2$  與 RMSE，加入 Administration 反而降低泛化能力。這三層說法能讓非技術讀者與技術讀者都理解同一個結論。

在版本控管方面，建議每一次提交都包含程式碼、圖表、模型檔與報告的版本標記。若只更新程式碼而未更新模型檔，簡報中的分數可能與實際預測結果不一致；若只更新報告而未保存實驗設定，後續也難以重現。因此，技術白皮書中的數字應被視為與特定程式版本綁定的結果，而不是永久不變的事實。

在模型倫理與使用限制方面，Profit 預測不應被用來單獨決定投資或資源配置。模型沒有理解公司團隊、產品品質、法規風險、產業週期與市場競爭，只是根據歷史支出欄位估計 Profit。因此，系統介面應加入提示文字，提醒使用者將預測結果作為輔助參考，而非保證收益。

為了讓本白皮規格書達到完整交付等級，以下補充專案在真實環境落地時應注意的細節。第一，資料輸入端必須維持欄位名稱一致，尤其 R&D Spend 與 Marketing Spend 不可被簡化為 RD 或 Marketing 而未同步更新 pipeline。第二，模型載入端應檢查 pkl 檔案是否存在、是否可被反序列化、是否包含前處理步驟。第三，預測結果應搭配輸入摘要一起輸出，方便使用者回頭檢查輸入是否正確。第四，若系統提供批次預測，應逐筆記錄錯誤原因，避免一筆資料格式錯誤導致整批失敗。

## 附錄 D：完整技術規格延伸條款

本附錄補充模型專案在規格化交付時應納入的條款。第一項是輸入資料契約。輸入資料契約應明確列出欄位名稱、資料型別、允許範圍、缺值策略、單位定義與錯誤處理方式。以本專案而言，R&D Spend 與 Marketing Spend 是最佳模型的核心輸入，因此任何部署端介面都必須保證這兩個欄位存在且為可轉換成數值的格式。若使用者輸入負值、空字串、非數字字元或極端離群值，系統不應直接產生預測，而應回傳明確訊息，要求修正輸入。這項設計可以避免模型被錯誤資料驅動，也能提升展示與實際使用時的可靠性。

第二項是模型輸出契約。輸出結果不應只是一個浮點數，而應包含可讀性足夠的輸出物件。建議輸出包含 predicted\_profit、model\_name、model\_version、feature\_set、prediction\_time、input\_summary 與 warning。predicted\_profit 是核心預測值，model\_name 說明採用的演算法，model\_version 可對應到訓練日期與程式版本，feature\_set 標示實際使用的欄位，prediction\_time 用於日誌追蹤，input\_summary 便於

使用者確認輸入是否正確，**warning** 則用來指出輸入超出訓練範圍或缺乏可信度的情況。這種輸出格式能讓模型從課堂作業提升為較完整的系統元件。

第三項是資料洩漏防護。資料洩漏是機器學習專案最常見且最隱蔽的錯誤之一。若標準化、編碼或特徵工程在切分訓練與測試資料之前就對全資料 **fit**，測試集資訊可能被間接帶入模型，導致評估分數過度樂觀。本專案使用 **Pipeline** 與 **ColumnTransformer** 的目的，就是讓前處理器只在訓練資料上學習必要統計量，再對測試資料進行 **transform**。規格文件應明確要求所有 **fit** 類操作只能出現在訓練流程內，測試集與未來預測資料只能套用已學得的轉換規則。

第四項是模型可解釋性。由於本專案最佳結果來自少數特徵，具備良好解釋條件。報告應指出 **R&D Spend** 是主要訊號來源，**Marketing Spend** 提供額外改善，而 **Administration** 在目前資料中屬於低貢獻或噪音特徵。若實際部署時採用線性模型，可以進一步呈現係數方向與相對大小；若採用 **Lasso**，則可說明正則化如何限制不必要特徵；若採用 **Random Forest** 作為比較模型，則應補充特徵重要性圖，但也要提醒樹模型在小資料上可能不穩定。

第五項是模型更新流程。模型不應在沒有評估的情況下被任意替換。更新流程應包含資料版本確認、重新訓練、交叉驗證、測試集評估、舊模型比較、部署前測試與版本標記。若新模型  $R^2$  稍高但 **RMSE** 較差，或新模型依賴更多特徵而降低可解釋性，則不一定適合替換。規格書應將「是否提升實際價值」作為替換條件，而不是只看單一數字。對本專案而言，兩特徵模型之所以被推薦，是因為它在高分數、低誤差、低複雜度與高可解釋性之間取得平衡。

第六項是錯誤處理與使用者提示。當 **predict\_profit()** 接收到不合法輸入時，應回傳具體且可行的訊息。例如缺少 **R&D Spend** 時，應提示「缺少必要欄位 **R&D Spend**」；輸入為文字時，應提示「欄位必須為數值」；輸入遠高於訓練資料範圍時，應提示「預測可能屬於外推，請審慎解讀」。良好的錯誤處理能降低使用者挫折，也能防止錯誤預測被誤用於決策。

第七項是展示與報告一致性。白皮書、簡報、程式輸出與模型檔案應使用同一組數字。若簡報中寫  $R^2=94.74\%$ ，白皮書中也應寫相同數字；若模型表中最佳特徵組合為 **R&D Spend** 與 **Marketing Spend**，部署章節也不應突然要求 **Administration**。這種一致性對作業評分非常重要，因為評審通常會從多個材料交叉檢查專案是否真正理解流程。若資料或程式重新執行後結果有變動，應建立新版本，而不是覆蓋舊文件造成矛盾。

第八項是商業解讀界線。模型顯示 **R&D Spend** 與 **Profit** 高度相關，但這不等於只要增加研發支出就必然增加利潤。相關性不是因果性，尤其在小資料集上更應謹慎。較安全的說法是：在目前資料中，**R&D Spend** 是最能解釋 **Profit** 差異的欄位，因此適合作為預測特徵。若要進一步主張因果關係，需要實驗設計、時間序列資料、控制變數或更完整的統計推論。白皮書應避免過度宣稱，以維持技術文件的可信度。

第九項是簡報轉換規格。若將本白皮書轉為二十頁簡報，應遵循由淺入深的敘事。前四頁說明背景、目標與 **CRISP-DM**；中間六頁說明資料與 **EDA**；接著五頁說明前處理、特徵工程、模型與調參；最後五頁呈現模型表現、關鍵洞察、部署成果、風險限制與結論。每一頁只放一個主訊息，避免將白皮書段落全部塞入投影片。簡報中的圖表應優先使用 **histograms**、**scatter plots**、**correlation heatmap** 與 **model performance table**，因為這些圖表最能支撐最終決策。

第十項是評審答辯準備。若被問到為什麼不用所有欄位，應回答：因為加入 **Administration** 後 **RMSE** 增加且  $R^2$  下降，代表它在目前資料上降低泛化能力。若被問到為什麼不用更複雜模型，應回答：**Random Forest** 在本次比較中未超越線性類模型，而且資料量只有 50 筆，簡潔模型更容易解釋且較不易過擬合。若被問到為什麼採用 **CRISP-DM**，應回答：**CRISP-DM** 能將業務問題、資料探索、資料準備、建模、評估與部署串成完整流程，使專案不只是模型訓練，而是可交付的資料科學工作。

本附錄補充模型專案在規格化交付時應納入的條款。第一項是輸入資料契約。輸入資料契約應明確列出欄位名稱、資料型別、允許範圍、缺值策略、單位定義與錯誤處理方式。以本專案而言，**R&D Spend** 與 **Marketing Spend** 是最佳模型的核心輸入，因此任何部署端介面都必須保證這兩個欄位存在且為可轉換成

數值的格式。若使用者輸入負值、空字串、非數字字元或極端離群值，系統不應直接產生預測，而應回傳明確訊息，要求修正輸入。這項設計可以避免模型被錯誤資料驅動，也能提升展示與實際使用時的可靠性。

第二項是模型輸出契約。輸出結果不應只是一個浮點數，而應包含可讀性足夠的輸出物件。建議輸出包含 `predicted_profit`、`model_name`、`model_version`、`feature_set`、`prediction_time`、`input_summary` 與 `warning`。`predicted_profit` 是核心預測值，`model_name` 說明採用的演算法，`model_version` 可對應到訓練日期與程式版本，`feature_set` 標示實際使用的欄位，`prediction_time` 用於日誌追蹤，`input_summary` 便於使用者確認輸入是否正確，`warning` 則用來指出輸入超出訓練範圍或缺乏可信度的情況。這種輸出格式能讓模型從課堂作業提升為較完整的系統元件。

第三項是資料洩漏防護。資料洩漏是機器學習專案最常見且最隱蔽的錯誤之一。若標準化、編碼或特徵工程在切分訓練與測試資料之前就對全資料 `fit`，測試集資訊可能被間接帶入模型，導致評估分數過度樂觀。本專案使用 `Pipeline` 與 `ColumnTransformer` 的目的，就是讓前處理器只在訓練資料上學習必要統計量，再對測試資料進行 `transform`。規格文件應明確要求所有 `fit` 類操作只能出現在訓練流程內，測試集與未來預測資料只能套用已學得的轉換規則。

第四項是模型可解釋性。由於本專案最佳結果來自少數特徵，具備良好解釋條件。報告應指出 `R&D Spend` 是主要訊號來源，`Marketing Spend` 提供額外改善，而 `Administration` 在目前資料中屬於低貢獻或噪音特徵。若實際部署時採用線性模型，可以進一步呈現係數方向與相對大小；若採用 `Lasso`，則可說明正則化如何限制不必要特徵；若採用 `Random Forest` 作為比較模型，則應補充特徵重要性圖，但也要提醒樹模型在小資料上可能不穩定。

第五項是模型更新流程。模型不應在沒有評估的情況下被任意替換。更新流程應包含資料版本確認、重新訓練、交叉驗證、測試集評估、舊模型比較、部署前測試與版本標記。若新模型  $R^2$  稍高但 `RMSE` 較差，或新模型依賴更多特徵而降低可解釋性，則不一定適合替換。規格書應將「是否提升實際價值」作為替換條件，而不是只看單一數字。對本專案而言，兩特徵模型之所以被推薦，是因為它在高分數、低誤差、低複雜度與高可解釋性之間取得平衡。

第六項是錯誤處理與使用者提示。當 `predict_profit()` 接收到不合法輸入時，應回傳具體且可行的訊息。例如缺少 `R&D Spend` 時，應提示「缺少必要欄位 `R&D Spend`」；輸入為文字時，應提示「欄位必須為數值」；輸入遠高於訓練資料範圍時，應提示「預測可能屬於外推，請審慎解讀」。良好的錯誤處理能降低使用者挫折，也能防止錯誤預測被誤用於決策。

第七項是展示與報告一致性。白皮書、簡報、程式輸出與模型檔案應使用同一組數字。若簡報中寫  $R^2=94.74\%$ ，白皮書中也應寫相同數字；若模型表中最佳特徵組合為 `R&D Spend` 與 `Marketing Spend`，部署章節也不應突然要求 `Administration`。這種一致性對作業評分非常重要，因為評審通常會從多個材料交叉檢查專案是否真正理解流程。若資料或程式重新執行後結果有變動，應建立新版本，而不是覆蓋舊文件造成矛盾。

第八項是商業解讀界線。模型顯示 `R&D Spend` 與 `Profit` 高度相關，但這不等於只要增加研發支出就必然增加利潤。相關性不是因果性，尤其在小資料集上更應謹慎。較安全的說法是：在目前資料中，`R&D Spend` 是最能解釋 `Profit` 差異的欄位，因此適合作為預測特徵。若要進一步主張因果關係，需要實驗設計、時間序列資料、控制變數或更完整的統計推論。白皮書應避免過度宣稱，以維持技術文件的可信度。

第九項是簡報轉換規格。若將本白皮書轉為二十頁簡報，應遵循由淺入深的敘事。前四頁說明背景、目標與 `CRISP-DM`；中間六頁說明資料與 `EDA`；接著五頁說明前處理、特徵工程、模型與調參；最後五頁呈現模型表現、關鍵洞察、部署成果、風險限制與結論。每一頁只放一個主訊息，避免將白皮書段落全部塞入投影片。簡報中的圖表應優先使用 `histograms`、`scatter plots`、`correlation heatmap` 與 `model performance table`，因為這些圖表最能支撐最終決策。

第十項是評審答辯準備。若被問到為什麼不用所有欄位，應回答：因為加入 `Administration` 後 `RMSE` 增加且  $R^2$  下降，代表它在目前資料上降低泛化能力。若被問到為什麼不用更複雜模型，應回答：`Random Forest` 在本次比較中未超越線性類模型，而且資料量只有 50 筆，簡潔模型更容易解釋且較不易過擬合。

若被問到為什麼採用 CRISP-DM，應回答：CRISP-DM 能將業務問題、資料探索、資料準備、建模、評估與部署串成完整流程，使專案不只是模型訓練，而是可交付的資料科學工作。

本附錄補充模型專案在規格化交付時應納入的條款。第一項是輸入資料契約。輸入資料契約應明確列出欄位名稱、資料型別、允許範圍、缺值策略、單位定義與錯誤處理方式。以本專案而言，R&D Spend 與 Marketing Spend 是最佳模型的核心輸入，因此任何部署端介面都必須保證這兩個欄位存在且為可轉換成數值的格式。若使用者輸入負值、空字串、非數字字元或極端離群值，系統不應直接產生預測，而應回傳明確訊息，要求修正輸入。這項設計可以避免模型被錯誤資料驅動，也能提升展示與實際使用時的可靠性。

第二項是模型輸出契約。輸出結果不應只是一個浮點數，而應包含可讀性足夠的輸出物件。建議輸出包含 predicted\_profit、model\_name、model\_version、feature\_set、prediction\_time、input\_summary 與 warning。predicted\_profit 是核心預測值，model\_name 說明採用的演算法，model\_version 可對應到訓練日期與程式版本，feature\_set 標示實際使用的欄位，prediction\_time 用於日誌追蹤，input\_summary 便於使用者確認輸入是否正確，warning 則用來指出輸入超出訓練範圍或缺乏可信度的情況。這種輸出格式能讓模型從課堂作業提升為較完整的系統元件。

第三項是資料洩漏防護。資料洩漏是機器學習專案最常見且最隱蔽的錯誤之一。若標準化、編碼或特徵工程在切分訓練與測試資料之前就對全資料 fit，測試集資訊可能被間接帶入模型，導致評估分數過度樂觀。本專案使用 Pipeline 與 ColumnTransformer 的目的，就是讓前處理器只在訓練資料上學習必要統計量，再對測試資料進行 transform。規格文件應明確要求所有 fit 類操作只能出現在訓練流程內，測試集與未來預測資料只能套用已學得的轉換規則。

第四項是模型可解釋性。由於本專案最佳結果來自少數特徵，具備良好解釋條件。報告應指出 R&D Spend 是主要訊號來源，Marketing Spend 提供額外改善，而 Administration 在目前資料中屬於低貢獻或噪音特徵。若實際部署時採用線性模型，可以進一步呈現係數方向與相對大小；若採用 Lasso，則可說明正則化如何限制不必要特徵；若採用 Random Forest 作為比較模型，則應補充特徵重要性圖，但也要提醒樹模型在小資料上可能不穩定。

第五項是模型更新流程。模型不應在沒有評估的情況下被任意替換。更新流程應包含資料版本確認、重新訓練、交叉驗證、測試集評估、舊模型比較、部署前測試與版本標記。若新模型  $R^2$  稍高但 RMSE 較差，或新模型依賴更多特徵而降低可解釋性，則不一定適合替換。規格書應將「是否提升實際價值」作為替換條件，而不是只看單一數字。對本專案而言，兩特徵模型之所以被推薦，是因為它在高分數、低誤差、低複雜度與高可解釋性之間取得平衡。

第六項是錯誤處理與使用者提示。當 predict\_profit() 接收到不合法輸入時，應回傳具體且可行的訊息。例如缺少 R&D Spend 時，應提示「缺少必要欄位 R&D Spend」；輸入為文字時，應提示「欄位必須為數值」；輸入遠高於訓練資料範圍時，應提示「預測可能屬於外推，請審慎解讀」。良好的錯誤處理能降低使用者挫折，也能防止錯誤預測被誤用於決策。

第七項是展示與報告一致性。白皮書、簡報、程式輸出與模型檔案應使用同一組數字。若簡報中寫  $R^2=94.74\%$ ，白皮書中也應寫相同數字；若模型表中最佳特徵組合為 R&D Spend 與 Marketing Spend，部署章節也不應突然要求 Administration。這種一致性對作業評分非常重要，因為評審通常會從多個材料交叉檢查專案是否真正理解流程。若資料或程式重新執行後結果有變動，應建立新版本，而不是覆蓋舊文件造成矛盾。

第八項是商業解讀界線。模型顯示 R&D Spend 與 Profit 高度相關，但這不等於只要增加研發支出就必然增加利潤。相關性不是因果性，尤其在小資料集上更應謹慎。較安全的說法是：在目前資料中，R&D Spend 是最能解釋 Profit 差異的欄位，因此適合作為預測特徵。若要進一步主張因果關係，需要實驗設計、時間序列資料、控制變數或更完整的統計推論。白皮書應避免過度宣稱，以維持技術文件的可信度。

第九項是簡報轉換規格。若將本白皮書轉為二十頁簡報，應遵循由淺入深的敘事。前四頁說明背景、目標與 CRISP-DM；中間六頁說明資料與 EDA；接著五頁說明前處理、特徵工程、模型與調參；最後五頁呈現模型表現、關鍵洞察、部署成果、風險限制與結論。每一頁只放一個主訊息，避免將白皮書段落全部塞入



投影片。簡報中的圖表應優先使用 histograms、scatter plots、correlation heatmap 與 model performance table，因為這些圖表最能支撐最終決策。

第十項是評審答辯準備。若被問到為什麼不用所有欄位，應回答：因為加入 Administration 後 RMSE 增加且  $R^2$  下降，代表它在目前資料上降低泛化能力。若被問到為什麼不用更複雜模型，應回答：Random Forest 在本次比較中未超越線性類模型，而且資料量只有 50 筆，簡潔模型更容易解釋且較不易過擬合。若被問到為什麼採用 CRISP-DM，應回答：CRISP-DM 能將業務問題、資料探索、資料準備、建模、評估與部署串成完整流程，使專案不只是模型訓練，而是可交付的資料科學工作。

本附錄補充模型專案在規格化交付時應納入的條款。第一項是輸入資料契約。輸入資料契約應明確列出欄位名稱、資料型別、允許範圍、缺值策略、單位定義與錯誤處理方式。以本專案而言，R&D Spend 與 Marketing Spend 是最佳模型的核心輸入，因此任何部署端介面都必須保證這兩個欄位存在且為可轉換成數值的格式。若使用者輸入負值、空字串、非數字字元或極端離群值，系統不應直接產生預測，而應回傳明確訊息，要求修正輸入。這項設計可以避免模型被錯誤資料驅動，也能提升展示與實際使用時的可靠性。

第二項是模型輸出契約。輸出結果不應只是一個浮點數，而應包含可讀性足夠的輸出物件。建議輸出包含 predicted\_profit、model\_name、model\_version、feature\_set、prediction\_time、input\_summary 與 warning。predicted\_profit 是核心預測值，model\_name 說明採用的演算法，model\_version 可對應到訓練日期與程式版本，feature\_set 標示實際使用的欄位，prediction\_time 用於日誌追蹤，input\_summary 便於使用者確認輸入是否正確，warning 則用來指出輸入超出訓練範圍或缺乏可信度的情況。這種輸出格式能讓模型從課堂作業提升為較完整的系統元件。

第三項是資料洩漏防護。資料洩漏是機器學習專案最常見且最隱蔽的錯誤之一。若標準化、編碼或特徵工程在切分訓練與測試資料之前就對全資料 fit，測試集資訊可能被間接帶入模型，導致評估分數過度樂觀。本專案使用 Pipeline 與 ColumnTransformer 的目的，就是讓前處理器只在訓練資料上學習必要統計量，再對測試資料進行 transform。規格文件應明確要求所有 fit 類操作只能出現在訓練流程內，測試集與未來預測資料只能套用已學得的轉換規則。

第四項是模型可解釋性。由於本專案最佳結果來自少數特徵，具備良好解釋條件。報告應指出 R&D Spend 是主要訊號來源，Marketing Spend 提供額外改善，而 Administration 在目前資料中屬於低貢獻或噪音特徵。若實際部署時採用線性模型，可以進一步呈現係數方向與相對大小；若採用 Lasso，則可說明正則化如何限制不必要特徵；若採用 Random Forest 作為比較模型，則應補充特徵重要性圖，但也要提醒樹模型在小資料上可能不穩定。

第五項是模型更新流程。模型不應在沒有評估的情況下被任意替換。更新流程應包含資料版本確認、重新訓練、交叉驗證、測試集評估、舊模型比較、部署前測試與版本標記。若新模型  $R^2$  稍高但 RMSE 較差，或新模型依賴更多特徵而降低可解釋性，則不一定適合替換。規格書應將「是否提升實際價值」作為替換條件，而不是只看單一數字。對本專案而言，兩特徵模型之所以被推薦，是因為它在高分數、低誤差、低複雜度與高可解釋性之間取得平衡。

第六項是錯誤處理與使用者提示。當 predict\_profit() 接收到不合法輸入時，應回傳具體且可行的訊息。例如缺少 R&D Spend 時，應提示「缺少必要欄位 R&D Spend」；輸入為文字時，應提示「欄位必須為數值」；輸入遠高於訓練資料範圍時，應提示「預測可能屬於外推，請審慎解讀」。良好的錯誤處理能降低使用者挫折，也能防止錯誤預測被誤用於決策。

第七項是展示與報告一致性。白皮書、簡報、程式輸出與模型檔案應使用同一組數字。若簡報中寫  $R^2=94.74\%$ ，白皮書中也應寫相同數字；若模型表中最佳特徵組合為 R&D Spend 與 Marketing Spend，部署章節也不應突然要求 Administration。這種一致性對作業評分非常重要，因為評審通常會從多個材料交叉檢查專案是否真正理解流程。若資料或程式重新執行後結果有變動，應建立新版本，而不是覆蓋舊文件造成矛盾。

第八項是商業解讀界線。模型顯示 R&D Spend 與 Profit 高度相關，但這不等於只要增加研發支出就必然增加利潤。相關性不是因果性，尤其在小資料集上更應謹慎。較安全的說法是：在目前資料中，R&D Spend

是最能解釋 Profit 差異的欄位，因此適合作為預測特徵。若要進一步主張因果關係，需要實驗設計、時間序列資料、控制變數或更完整的統計推論。白皮書應避免過度宣稱，以維持技術文件的可信度。

第九項是簡報轉換規格。若將本白皮書轉為二十頁簡報，應遵循由淺入深的敘事。前四頁說明背景、目標與 CRISP-DM；中間六頁說明資料與 EDA；接著五頁說明前處理、特徵工程、模型與調參；最後五頁呈現模型表現、關鍵洞察、部署成果、風險限制與結論。每一頁只放一個主訊息，避免將白皮書段落全部塞入投影片。簡報中的圖表應優先使用 histograms、scatter plots、correlation heatmap 與 model performance table，因為這些圖表最能支撐最終決策。

第十項是評審答辯準備。若被問到為什麼不用所有欄位，應回答：因為加入 Administration 後 RMSE 增加且  $R^2$  下降，代表它在目前資料上降低泛化能力。若被問到為什麼不用更複雜模型，應回答：Random Forest 在本次比較中未超越線性類模型，而且資料量只有 50 筆，簡潔模型更容易解釋且較不易過擬合。若被問到為什麼採用 CRISP-DM，應回答：CRISP-DM 能將業務問題、資料探索、資料準備、建模、評估與部署串成完整流程，使專案不只是模型訓練，而是可交付的資料科學工作。

本附錄補充模型專案在規格化交付時應納入的條款。第一項是輸入資料契約。輸入資料契約應明確列出欄位名稱、資料型別、允許範圍、缺值策略、單位定義與錯誤處理方式。以本專案而言，R&D Spend 與 Marketing Spend 是最佳模型的核心輸入，因此任何部署端介面都必須保證這兩個欄位存在且為可轉換成數值的格式。若使用者輸入負值、空字串、非數字字元或極端離群值，系統不應直接產生預測，而應回傳明確訊息，要求修正輸入。這項設計可以避免模型被錯誤資料驅動，也能提升展示與實際使用時的可靠性。

第二項是模型輸出契約。輸出結果不應只是一個浮點數，而應包含可讀性足夠的輸出物件。建議輸出包含 predicted\_profit、model\_name、model\_version、feature\_set、prediction\_time、input\_summary 與 warning。predicted\_profit 是核心預測值，model\_name 說明採用的演算法，model\_version 可對應到訓練日期與程式版本，feature\_set 標示實際使用的欄位，prediction\_time 用於日誌追蹤，input\_summary 便於使用者確認輸入是否正確，warning 則用來指出輸入超出訓練範圍或缺乏可信度的情況。這種輸出格式能讓模型從課堂作業提升為較完整的系統元件。

第三項是資料洩漏防護。資料洩漏是機器學習專案最常見且最隱蔽的錯誤之一。若標準化、編碼或特徵工程在切分訓練與測試資料之前就對全資料 fit，測試集資訊可能被間接帶入模型，導致評估分數過度樂觀。本專案使用 Pipeline 與 ColumnTransformer 的目的，就是讓前處理器只在訓練資料上學習必要統計量，再對測試資料進行 transform。規格文件應明確要求所有 fit 類操作只能出現在訓練流程內，測試集與未來預測資料只能套用已學得的轉換規則。

第四項是模型可解釋性。由於本專案最佳結果來自少數特徵，具備良好解釋條件。報告應指出 R&D Spend 是主要訊號來源，Marketing Spend 提供額外改善，而 Administration 在目前資料中屬於低貢獻或噪音特徵。若實際部署時採用線性模型，可以進一步呈現係數方向與相對大小；若採用 Lasso，則可說明正則化如何限制不必要特徵；若採用 Random Forest 作為比較模型，則應補充特徵重要性圖，但也要提醒樹模型在小資料上可能不穩定。

第五項是模型更新流程。模型不應在沒有評估的情況下被任意替換。更新流程應包含資料版本確認、重新訓練、交叉驗證、測試集評估、舊模型比較、部署前測試與版本標記。若新模型  $R^2$  稍高但 RMSE 較差，或新模型依賴更多特徵而降低可解釋性，則不一定適合替換。規格書應將「是否提升實際價值」作為替換條件，而不是只看單一數字。對本專案而言，兩特徵模型之所以被推薦，是因為它在高分數、低誤差、低複雜度與高可解釋性之間取得平衡。

第六項是錯誤處理與使用者提示。當 predict\_profit() 接收到不合法輸入時，應回傳具體且可行的訊息。例如缺少 R&D Spend 時，應提示「缺少必要欄位 R&D Spend」；輸入為文字時，應提示「欄位必須為數值」；輸入遠高於訓練資料範圍時，應提示「預測可能屬於外推，請審慎解讀」。良好的錯誤處理能降低使用者挫折，也能防止錯誤預測被誤用於決策。

第七項是展示與報告一致性。白皮書、簡報、程式輸出與模型檔案應使用同一組數字。若簡報中寫  $R^2=94.74\%$ ，白皮書中也應寫相同數字；若模型表中最佳特徵組合為 R&D Spend 與 Marketing Spend，部

署章節也不應突然要求 **Administration**。這種一致性對作業評分非常重要，因為評審通常會從多個材料交叉檢查專案是否真正理解流程。若資料或程式重新執行後結果有變動，應建立新版本，而不是覆蓋舊文件造成矛盾。

第八項是商業解讀界線。模型顯示 **R&D Spend** 與 **Profit** 高度相關，但這不等於只要增加研發支出就必然增加利潤。相關性不是因果性，尤其在小資料集上更應謹慎。較安全的說法是：在目前資料中，**R&D Spend** 是最能解釋 **Profit** 差異的欄位，因此適合作為預測特徵。若要進一步主張因果關係，需要實驗設計、時間序列資料、控制變數或更完整的統計推論。白皮書應避免過度宣稱，以維持技術文件的可信度。

第九項是簡報轉換規格。若將本白皮書轉為二十頁簡報，應遵循由淺入深的敘事。前四頁說明背景、目標與 **CRISP-DM**；中間六頁說明資料與 **EDA**；接著五頁說明前處理、特徵工程、模型與調參；最後五頁呈現模型表現、關鍵洞察、部署成果、風險限制與結論。每一頁只放一個主訊息，避免將白皮書段落全部塞入投影片。簡報中的圖表應優先使用 **histograms**、**scatter plots**、**correlation heatmap** 與 **model performance table**，因為這些圖表最能支撐最終決策。

第十項是評審答辯準備。若被問到為什麼不用所有欄位，應回答：因為加入 **Administration** 後 **RMSE** 增加且  $R^2$  下降，代表它在目前資料上降低泛化能力。若被問到為什麼不用更複雜模型，應回答：**Random Forest** 在本次比較中未超越線性類模型，而且資料量只有 50 筆，簡潔模型更容易解釋且較不易過擬合。若被問到為什麼採用 **CRISP-DM**，應回答：**CRISP-DM** 能將業務問題、資料探索、資料準備、建模、評估與部署串成完整流程，使專案不只是模型訓練，而是可交付的資料科學工作。